

B 4 本読み第 5 回

内積と直交性

2020/05/08

実装担当：松林慶祐 / テスト担当：重見開

目次

- 実装環境
- ユークリッド空間
- n -ノルム
- コサイン類似度
- 正規直交基底とユニタリ行列
- グラム・シュミットの正規直交化
- 正射影
- まとめ

環境

- 実装環境
 - macOS Catalina (10.15.4)
 - Python 3.7.7
- スライド制作環境
 - Windows Home 64bit (1903)
 - Jupyter Notebook 6.0.3
 - Python 3.7.7

ユークリッド空間

ユークリッド内積を導入した空間のこと。一般的に知られている内積はユークリッド内積といい、二つのベクトル $\mathbf{x}, \mathbf{y} \in \mathbb{C}^N$ に対して、以下の式で表される。

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{y}^H \mathbf{x} = x_1 \overline{y_1} + x_2 \overline{y_2} + \cdots + x_N \overline{y_N}$$

また、内積はスカラーであることから、順番を入れ替えると共役になる。

$$\langle \mathbf{y}, \mathbf{x} \rangle = \mathbf{x}^H \mathbf{y} = (\mathbf{y}^H \mathbf{x})^H = \overline{\mathbf{y}^H \mathbf{x}} = \overline{\langle \mathbf{x}, \mathbf{y} \rangle}$$

実数の N 次元ユークリッド空間の場合は、
共役を考える必要がないため、簡潔に表記できる。

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{y}^T \mathbf{x} = x_1 y_1 + x_2 y_2 + \cdots + x_N y_N$$

ベクトルの直交性

二つのベクトル $x, y \in \mathbb{C}^N$ の内積に対して,

$$\langle x, y \rangle = 0$$

が成り立つとき,
 x と y は直交するという.

実装課題 1

ユークリッド内積を求める（ついでに直交性も判定）関数を実装

関数の動作

1. 二つのベクトルを入力（縦ベクトルを想定）
2. 縦と横の場合はエラー，横同士の場合は縦に変換
3. 2つ目に入力されたベクトルを共役なものに変換
4. 成分同士を掛け合わせて加算
5. 内積の結果が0であったら直交であると判断
6. 結果を縦ベクトルで出力

行列ベクトルを表すためにnumpyを使用

```
In [1]: import numpy as np
```



```
In [2]: def euclidean_inner_product(vector1, vector2, show_orth=False):
# numpy配列変換
x = np.array(vector1)
y = np.array(vector2)
# エラー処理
try:
    if not x.shape == y.shape: #横×縦, 成分数違いを検知
        raise ValueError("ベクトルのサイズが違います")
    else:
        pass
except ValueError as ve:
    print(ve)
    return # 関数を抜けてNoneを返す
# 共役をとる
conj_y = y.conj()
# 成分ごとの積をとって加算
tmp = []
for i in range(x.size):
    tmp.append(x[i][0] * conj_y[i][0])
res = sum(tmp)
# 直交性の判断
if round(res, 7) == 0:
    is_orthogonal = True
else:
    is_orthogonal = False
# 直交性の判別を返すかどうか
if show_orth == True:
    return res, is_orthogonal
else:
    return res
```

In [3]:

```
x = [[2-1j], [1j], [-1j]]
y = [[3j], [1+1j], [4+1j]]
x_ip_y, xy_orth = euclidean_inner_product(x, y, show_orth=True)
y_ip_x, yx_orth = euclidean_inner_product(y, x, show_orth=True)
print("<x,y> = {0}, 直交かどうか={1}¥n<y,x> = {2}, 直交かどうか={3}".format(x_ip_y, xy_orth,
h, y_ip_x, yx_orth))
x = [[2], [3], [-1]]
y = [[4], [-2], [2]]
x_ip_y, xy_orth = euclidean_inner_product(x, y, show_orth=True)
y_ip_x, yx_orth = euclidean_inner_product(y, x, show_orth=True)
print("<x,y> = {0}, 直交かどうか={1}¥n<y,x> = {2}, 直交かどうか={3}".format(x_ip_y, xy_orth,
h, y_ip_x, yx_orth))
```

<x,y> = (-3-9j), 直交かどうか=False

<y,x> = (-3+9j), 直交かどうか=False

<x,y> = 0, 直交かどうか=True

<y,x> = 0, 直交かどうか=True

ノルム

ベクトルの長さを決める量のこと.
内積空間のベクトル \boldsymbol{x} に対して

$$\|\boldsymbol{x}\| = \sqrt{\langle \boldsymbol{x}, \boldsymbol{x} \rangle}$$

をノルムと呼ぶ.

特に, ノルムが 1 のとき, \boldsymbol{x} は**単位ベクトル**であるという.

ユークリッド空間のベクトル $\boldsymbol{x} \in \mathbb{C}^N$ の場合に, ノルムは

$$\|\boldsymbol{x}\| = \sqrt{\sum_{i=1}^N |x_i|^2}$$

のように要素で書き下すことができ, 特にこのノルムを l_2 ノルム, または 2- ノルムと呼ぶ.

一方,

$$\|\boldsymbol{x}\|_1 = \sum_{i=1}^N |x_i|$$

のように定義されるノルムを, l_1 ノルム, または 1- ノルムとよび, 信号処理や機械学習で疎性 (スパース性) を測るのに広く使われる.

実装課題 2

n- ノルムを求める（引数はベクトルとn）関数を実装

関数の動作

1. ノルムを求めるベクトルと n を入力する
2. ベクトルの成分ごとに絶対値をとり, n 乗する
3. n 乗したものの総和をとり, n 乗根を求める

```

In [4]: def n_norm(vector, n=2):
        # 縦ベクトルに変換
        vec = np.array(vector).reshape(-1, 1)

        # 計算
        tmp = []
        for i in range(vec.size):
            # print(abs(vec[i][0]))
            tmp.append(abs(vec[i][0]) ** n) # 絶対値のn乗 (たぶん複素数もOK)

        # 全部加算してn乗根
        res = sum(tmp)**(1 / n)

        return res

print("整数のみ {0}".format(x))
x = [[-3], [2], [2], [3]]
norm1 = n_norm(x, 1)
norm2 = n_norm(x)
print("1- ノルムは {0}¥n2- ノルムは {1}".format(norm1, norm2))
print("異なる型同士 {0}".format(x))
x = [[-3], [5.6], [4+1j]]
norm1 = n_norm(x, 1)
norm2 = n_norm(x)
print("1- ノルムは {0}¥n2- ノルムは {1}".format(norm1, norm2))

```

整数のみ [[2], [3], [-1]]

1- ノルムは 10.0

2- ノルムは 5.0990195135927845

異なる型同士 [[-3], [2], [2], [3]]

1- ノルムは 12.72310562561766

2- ノルムは 7.573638491504595

コサイン類似度

ノルムと内積によって導入される, 二つのベクトルの角度のことで, パターン間の距離を測るのに用いられる.

$$\cos \theta = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$

ベクトル同士の向きが近いほどなす角度が小さくなるので, コサイン類似度は小さくなり, 向きが異なるほど, コサイン類似度は大きくなる.

コサイン類似度は -1 から 1 の値をとり,
コサイン類似度から $0 \leq \theta \leq \pi$ の範囲で決まる θ を**角度**と呼ぶ.

実装課題 3

コサイン類似度を求める関数を実装

関数の動作

1. 二つのベクトルを入力
2. 課題 1 の関数を使って内積を計算
3. 課題 2 の関数を使ってそれぞれのベクトルの 2- ノルムを計算
4. 定義に従ってコサイン類似度を計算

```
In [5]: def cosine_similarity(vector1, vector2):  
        # 内積計算  
        ip_xy = euclidean_inner_product(vector1, vector2)  
  
        # ノルム計算  
        norm_x = n_norm(vector1)  
        norm_y = n_norm(vector2)  
  
        # コサイン類似度計算  
        res = ip_xy / (norm_x * norm_y)  
  
        return res  
  
x = [[0.4], [5.6], [-0.07]]  
y = [[-1.1], [0.22], [-3.3]]  
print("コサイン類似度は {0}".format(cosine_similarity(x, y)))
```

コサイン類似度は 0.05227442125730368

正規直交基底

N次元ベクトル空間の基底ベクトル $\{\mathbf{u}_i\}_{i=1}^N$ が

- すべて互いに直交
- すべての基底ベクトルのノルムが 1

のとき, この基底を**正規直交基底**と呼ぶ.

正規直交展開

N 次元ベクトル空間 V の基底 $\{\boldsymbol{u}_i\}_{i=1}^N$ が正規直交性を満たすとき, V 内のベクトル $\boldsymbol{x} \in V$ は基底 $\{\boldsymbol{u}_i\}_{i=1}^N$ を用いて,

$$\boldsymbol{x} = \langle \boldsymbol{x}, \boldsymbol{u}_1 \rangle \boldsymbol{u}_1 + \langle \boldsymbol{x}, \boldsymbol{u}_2 \rangle \boldsymbol{u}_2 + \cdots + \langle \boldsymbol{x}, \boldsymbol{u}_N \rangle \boldsymbol{u}_N$$

と展開できる. これを**正規直交展開**という.

$\langle \boldsymbol{x}, \boldsymbol{u}_N \rangle$ が展開係数となっている.

ユニタリ行列

ある行列の逆行列とエルミート転置が一致しているような行列のこと.
すなわち, $\mathbf{A}^{-1} = \mathbf{A}^H$ より $\mathbf{A}\mathbf{A}^H = \mathbf{A}^H\mathbf{A} = \mathbf{I}$
が成り立つような行列のことをユニタリ行列という.

ユニタリ行列の列ベクトルは正規直交性を持つ.

正規直交展開の展開係数 $c_i = \langle \mathbf{x}, \mathbf{u}_i \rangle = \mathbf{u}_i^H \mathbf{x}$ を並べたベクトルを考えると,

$$\mathbf{c} = \begin{bmatrix} \mathbf{u}_1^H \mathbf{x} \\ \mathbf{u}_2^H \mathbf{x} \\ \vdots \\ \mathbf{u}_N^H \mathbf{x} \end{bmatrix} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N]^H \mathbf{x} = \mathbf{U}^H \mathbf{x}$$

のように表せる. この時 \mathbf{U} は正規直交基底が列ベクトルとなっている行列である. つまり \mathbf{U} の列ベクトルが正規直交性をもつので, \mathbf{U} はユニタリ行列である.

ノルムについて考えると,

$$\|\mathbf{c}\|^2 = \|\mathbf{U}^H \mathbf{x}\|^2 = \|\mathbf{x}\|^2$$

となっていることから, ユニタリ行列は**ノルム変えない**性質を持つ.

実装課題 4

ユニタリ行列かどうか判定する関数を実装

判別方法

1. $\mathbf{A}^{-1} = \mathbf{A}^H$ (逆行列とエルミート転置が一致する)
2. $\mathbf{A}\mathbf{A}^H = \mathbf{A}^H\mathbf{A} = \mathbf{I}$ (逆行列とエルミート転置の積が単位行列になる)

⇒ 2番の方法を採用

関数の動作

1. 行列を入力
2. 入力された行列のエルミート転置を取得
3. 行列とそのエルミート転置の積を計算
4. 用意しておいた単位行列と積が等しいか判別

```
In [6]: def unitary_matrix(matrix):  
  
    uni = np.array(matrix)  
    her_mat = np.conjugate(uni.T)  
    ide_mat = uni @ her_mat  
    ide_mat2 = np.identity(len(uni))  
  
    for i in range(len(uni)):  
        for j in range(len(uni)):  
            if not round(ide_mat[i][j] - ide_mat2[i][j], 7) == 0:  
                unitary = False  
            else:  
                unitary = True  
    return unitary
```

```
In [7]: mat = (1/math.sqrt(2)) * np.array([[1, 1], [-1j, 1j]])  
print(unitary_matrix(mat))  
mat = np.array([[1, 1], [-1j, 1j]])  
print(unitary_matrix(mat))
```

```
-----  
NameError                                Traceback (most recent call last)  
<ipython-input-7-c8a67088e0fc> in <module>  
----> 1 mat = (1/math.sqrt(2)) * np.array([[1, 1], [-1j, 1j]])  
      2 print(unitary_matrix(mat))  
      3 mat = np.array([[1, 1], [-1j, 1j]])  
      4 print(unitary_matrix(mat))  
  
NameError: name 'math' is not defined
```

グラム・シュミットの正規直交化

直交ではない基底から，正規直交基底を生成する方法のこと．

以下の手順により，直交しているとは限らない基底 $\{\mathbf{u}_i\}_{i=1}^N$ から 正規直交基底 $\{\mathbf{v}_i\}_{i=1}^N$ を得ることができる．

$$1. \mathbf{v}_1 = \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|}$$

2. $i = 2, 3, \dots, N$ に対し以下の操作を繰り返す

$$A. \hat{\mathbf{u}}_i = \sum_{j=1}^{i-1} \langle \mathbf{u}_i, \mathbf{v}_j \rangle$$

$$B. \mathbf{v}_i = \frac{\mathbf{u}_i - \hat{\mathbf{u}}_i}{\|\mathbf{u}_i - \hat{\mathbf{u}}_i\|}$$

実装課題 5

基底をグラム・シュミットの正規直交化する関数を実装

関数の動作

1. 正規直交化したい基底を並べた行列を入力
2. 手順 (1) のとおりに 1 本目の基底を計算
3. $i = 2, 3, \dots, N$ に対し for 文を回すことで手順 (2) の A と B を計算し残りの基底を計算

```
In [ ]: def Gram_Schmidt_orthonormalization(matrix):  
    # numpy基底行列matrix_u  
    matrix_u = np.array(matrix)  
    u_len = len(matrix_u)  
  
    # 第一手順  
    u0 = np.array(matrix_u[:, 0]).reshape(-1, 1) # 一つ目の基底を縦ベクトルで取得  
    v0 = u0 / (n_norm(u0))  
    matrix_v = np.array(v0).reshape(-1, 1)  
  
    # 第二手順  
    for i in range(1, u_len):  
        ui = np.array(matrix_u[:, i]).reshape(-1, 1)  
        u_ = np.zeros((u_len, 1))  
        for j in range(i):  
            vj = np.array(matrix_v[:, j]).reshape(-1, 1)  
            u_ = u_ + euclidean_inner_product(ui, vj) * vj  
        vi = (ui - u_) / (n_norm((ui - u_)))  
        matrix_v = np.hstack((matrix_v, vi))  
    return matrix_v
```

```
In [ ]: u = np.array([[1, 1, 1], [1, -1, 2], [-1, 1, 3]]).T
print(Gram_Schmidt_orthonormalization(u))
#
```


正射影

N 次元空間 V に, ある部分空間 W を定義したとき, 任意の $x \in V$ に対して

$$\langle y, x - y \rangle = 0$$

となるような $y \in W$ を, x の W への**正射影** (直交射影) という.

V の基底 $\{\boldsymbol{u}_i\}_{i=1}^N$ が正規直交性を満たすとき, 部分空間 W に対する \boldsymbol{x} の正射影を特に $\boldsymbol{P}_w \boldsymbol{x}$ と表記し, 以下のように表すことができる.

$$\boldsymbol{P}_w \boldsymbol{x} = \sum_{i=1}^r \langle \boldsymbol{x}, \boldsymbol{u}_i \rangle \boldsymbol{u}_i = \left(\sum_{i=1}^r \boldsymbol{u}_i \boldsymbol{u}_i^H \right) \boldsymbol{x}$$

実装課題 6

正射影を求める関数を実装

関数の動作

1. 基底を並べた行列と射影したいベクトルを入力する.
2. 1つ目の基底ベクトルと射影したいベクトルの内積を計算し, 1つ目の基底ベクトルをその値でスカラ倍する.
3. 2つ目の基底ベクトルについても同様に行い, 1つ目の結果とのベクトル和をとる.
4. それ以降も同様にして, 基底ベクトルを内積でスカラ倍したものの総和をとる.
5. ベクトルが総和されたものを出力する.

```
In [ ]: def orthogonal_projection(matrix, vector):  
        x = np.array(vector).reshape(-1, 1)  
        matrix_u = np.array(matrix)  
        u_len = len(matrix_u)  
        pwx = np.zeros((u_len, 1))  
        for i in range(u_len):  
            ui = np.array(matrix_u[:, i]).reshape(-1, 1)  
            pwx = pwx + euclidean_inner_product(x, ui) * ui  
        return pwx
```

```
In [ ]: x = [[2], [3], [-1]]  
        Pw = [[1, 0, 0], [0, 1, 0], [0, 0, 0]]  
        print(orthogonal_projection(Pw, x))
```



まとめ

- ユークリッド内積や正規直交性について理解した
- Jupyter Notebook の使い方について理解した
 - OS の差を意識することなく使えた
 - RISE でのスライドづくりは Keynote, Powerpoint に比べて手間がかかった
- 例外処理の実装が難しかった